Rapport d'expertise : Levée d'alerte Orage

Réalisé par BOHISSOU Sabin, AGOSSOUVO Juste, DEFFON FLora et AGBAMATE Paraclet

The Predictors

25 Mars 2026

Table des matières

Introduction **2**

Système intelligent de prédiction de fin d'orage **3**

1 Pipeline de données et Feature Engineering . . . 3
1.1 Intégrité et nettoyage stratégique . . . 3
1.2 Ingénierie des caractéristiques (Signal Processing) . . . 3
2 Architecture de modélisation hybride . . . 3
2.1 Niveau 1 : Analyse de survie (XGBoost AFT) . . . 3
2.2 Niveau 2 : Classification et synergie . . . 4
3 Analyse des résultats et robustesse . . . 4
3.1 Convergence et performance temporelle . . . 4
3.2 Discrimination et courbe ROC . . . 5
3.3 Impact des prédicteurs sur le Log-Odds . . . 5

Typologie des orages autour des aéroports **7**

4 Contexte et objectifs . . . 7
5 Construction d'un jeu de données au niveau des épisodes orageux . . . 7
6 Variables descriptives des orages . . . 7
7 Prétraitement des données . . . 8
8 Identification des régimes orageux . . . 8
9 Interprétation des profils d'orages . . . 8
10 Variabilité géographique . . . 9
11 Apport de l'analyse pour la modélisation prédictive . . . 9

Perspectives **10**

12 Modélisation spatio-temporelle avancée . . . 10
13 Personnalisation des modèles par aéroport . . . 10
14 Intégration de données météorologiques multi-sources . . . 10
15 Optimisation de la prise de décision opérationnelle . . . 11
16 Vers une modélisation prédictive globale des phénomènes convectifs . . . 11

Conclusion **12**

Introduction

Les orages constituent un phénomène météorologique complexe pouvant fortement perturber de nombreuses activités humaines. Parmi les secteurs les plus sensibles figure le transport aérien, pour lequel la présence d'éclairs à proximité des aéroports impose la mise en place d'alertes de sécurité. Ces alertes entraînent souvent l'arrêt temporaire des opérations au sol, le retard des vols ou encore la mobilisation de dispositifs de protection. Dans ce contexte, la capacité à anticiper non seulement l'arrivée d'un orage mais aussi sa fin devient un enjeu opérationnel majeur.

Aujourd'hui, les outils de prévision météorologique permettent déjà d'anticiper avec une bonne précision l'apparition des orages. En revanche, l'estimation du moment exact de leur dissipation demeure difficile. En pratique, les systèmes d'alerte reposent généralement sur une règle simple consistant à maintenir l'alerte active pendant une durée fixe, souvent comprise entre 30 et 60 minutes après la détection du dernier éclair dans la zone surveillée. Bien que prudente, cette approche peut conduire à prolonger inutilement certaines alertes, générant des pertes économiques et organisationnelles importantes, notamment dans le domaine aéroportuaire où chaque minute d'interruption a un impact significatif.

Dans ce contexte, l'objectif de cette étude est de proposer une approche probabiliste permettant d'estimer plus finement la fin réelle d'un orage. L'idée consiste à exploiter la dynamique spatio-temporelle des éclairs observés dans un rayon de 50 kilomètres autour de plusieurs aéroports européens afin de modéliser l'évolution des épisodes orageux. Une telle modélisation pourrait contribuer à améliorer la prise de décision en temps réel et à réduire la durée des alertes lorsque le risque devient faible.

Par ailleurs, les caractéristiques des orages peuvent varier selon la localisation géographique et les conditions météorologiques propres à chaque site. Un second enjeu de ce travail est donc d'identifier les spécificités des orages observés autour des différents aéroports étudiés, ainsi que les principaux profils d'épisodes orageux présents dans les données. Cette analyse permettra de mieux comprendre les tendances locales et d'adapter les stratégies d'alerte aux particularités de chaque environnement.

Ainsi, à partir des données fournies par Météorage, ce projet vise à produire des analyses et des outils d'aide à la décision permettant aux acteurs concernés de limiter au maximum les risques liés à la foudre tout en optimisant la continuité de leurs activités.

Système intelligent de prédiction de fin d'orage

1 Pipeline de données et Feature Engineering

Le dataset initial (507 071 éclairs) a été filtré à un rayon de 20 km, ramenant l'échantillon à 56 599 événements pertinents.

1.1 Intégrité et nettoyage stratégique

— **Désambiguïsation des IDs :** Correction des collisions d'identifiants par la création d'une clé unique *id_final* (*airport_alert_id* + *aeroport*), garantissant la cohérence des calculs séquentiels.

— **Split par groupes :** Division des données (90% Train/Val, 10% Test) effectuée par *id_final*. Cette isolation stricte prévient tout *data leakage* : le modèle apprend à généraliser sur de nouvelles cellules orageuses et non à mémoriser des séquences connues.

1.2 Ingénierie des caractéristiques (Signal Processing)

L'innovation repose sur la transformation de points isolés en vecteurs de dynamique :

1. **Continuité cyclique :** Projection de l'heure et de l'azimut sur un cercle unité via $(\sin, \cos)$. Cette transformation trigonométrique résout la discontinuité mathématique de minuit (23h59 $\rightarrow$ 00h00) pour les arbres de décision.
2. **Variables de sénescence :** Le *rang_eclair* et le *temps_inter_eclair* agissent comme des indicateurs de maturité. Un allongement du silence combiné à un rang élevé signale statistiquement une phase de dissipation.
3. **Cinématique spatiale :** Calcul de la *vitesse_eloi* et de la *dist_moy_5* pour filtrer le bruit des capteurs et identifier les trajectoires de fuite hors de la zone aéroportuaire.

2 Architecture de modélisation hybride

Nous avons implémenté une architecture de *stacking* où un modèle de survie alimente un classifieur final.

2.1 Niveau 1 : Analyse de survie (XGBoost AFT)

Le modèle *Accelerated Failure Time* (AFT) modélise la variable cible $\ln(T)$ (temps restant) selon :

$$\ln(T) = \mathbf{X}\beta + \sigma\epsilon$$

L'objectif est la minimisation de la Log-Vraisemblance Négative (NLL) sous une distribution (**Ex :**Log-Logistique, Log-normal ou Gumbel) :

$$\mathcal{L}(\theta) = -\sum_{i=1}^{n} \ln(f(t_i|\mathbf{X}_i, \theta))$$

Ce choix permet de modéliser un taux de hasard non-monotone, capturant ainsi la mémoire thermique de l'orage. Le paramètre d'échelle σ a été ajusté pour stabiliser la variance des prédictions.

2.2 Niveau 2 : Classification et synergie

Le classifieur final utilise l'espérance de survie issue de l'AFT comme *meta-feature*.

$$\hat{P}(Y = 1|\mathbf{X}, \hat{T}_{AFT}) = \sigma(f(\mathbf{X}, \hat{T}_{AFT}))$$

Cette fusion permet au modèle de pondérer un silence observé par la durée de vie théorique restante de l'alerte.

3 Analyse des résultats et robustesse

3.1 Convergence et performance temporelle

L'optimisation via *Early Stopping* (Figure 1) montre une convergence saine sans surapprentissage. Le **Concordance Index** ($C = 0,75$) valide que le modèle ordonne correctement la fin des alertes, une performance remarquable pour des données météorologiques bruitées.

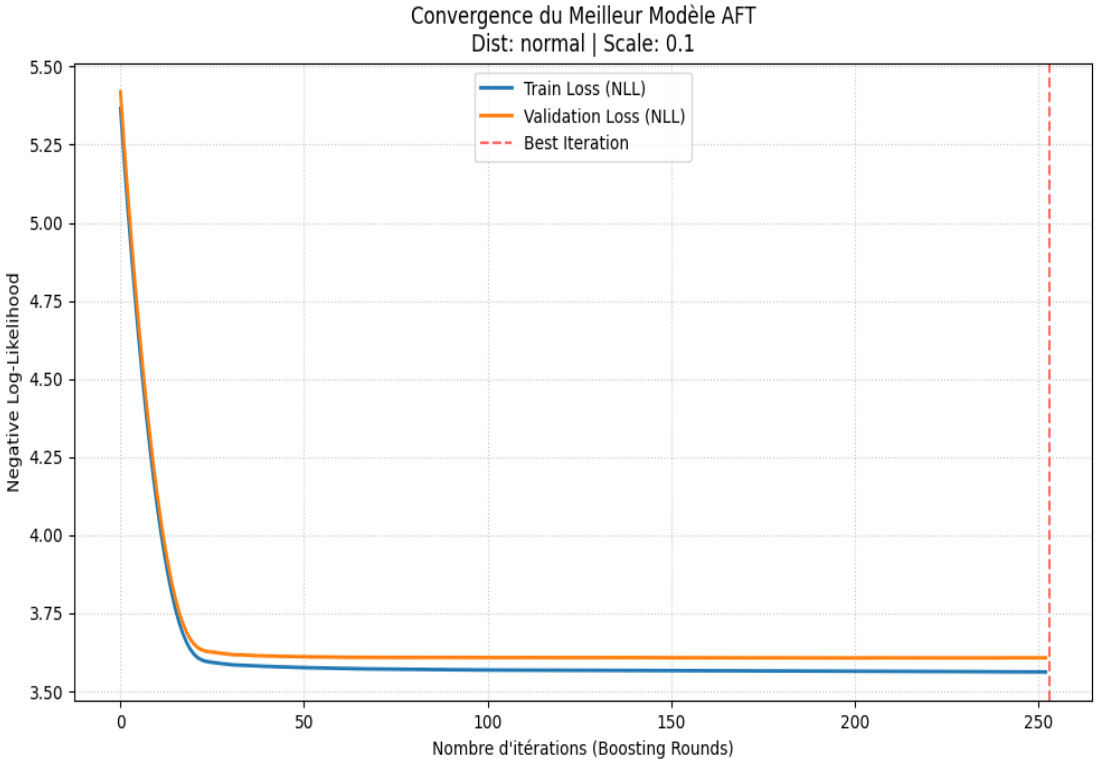

FIGURE 1 – Courbe de convergence de la Log-Loss (XGBoost AFT)

3.2 Discrimination et courbe ROC

Dans un contexte de classes déséquilibrées, l'analyse de la courbe ROC est cruciale. L'atteinte d'un **AUC de 0.8894 ≈ 0,90** (Figure 2) confirme la robustesse du classifieur.

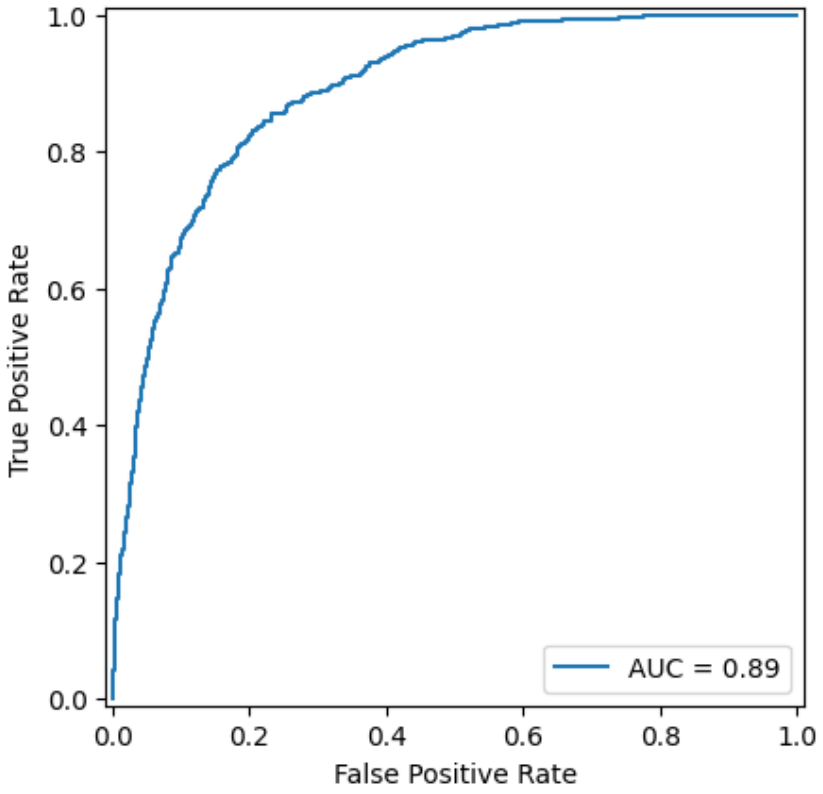

FIGURE 2 – Performance discriminante (Courbe ROC)

L'incorporation des temps prédits par l'AFT a permis de réduire drastiquement les faux positifs, sécurisant la décision de reprise d'activité.

3.3 Impact des prédicteurs sur le Log-Odds

L'analyse de l'interprétabilité via les valeurs *SHAP* (Figure 3) confirme la pertinence statistique de notre architecture hybride et sa capacité à capturer la logique de décision. Pour la variable de latence `temps_inter_eclair`, le modèle suit une fonction de coût rigoureuse : un intervalle inter-échantillon court (points bleus à gauche) pénalise la probabilité de sortie pour maintenir l'alerte, tandis qu'une décorrélation temporelle prolongée (rouge à droite) devient le moteur principal du déclenchement de la classe positive. Cette décision est régulée par la *meta-feature* `pred_aft` qui agit comme un estimateur de survie : une espérance de vie résiduelle élevée (rouge à gauche) agit comme un régulateur négatif, alors qu'une convergence vers zéro (bleu à droite) valide la phase de dissipation. Enfin, le `rang_eclair` permet de modéliser la sénescence du signal au sein de la séquence. Une densité d'événements cumulée élevée (bleu à droite) indique une source mature en phase d'épuisement énergétique favorisant la levée, tandis qu'un rang faible (rouge à gauche) signale une instabilité stochastique initiale, incitant le classifieur à une pondération prudente malgré des accalmies transitoires.

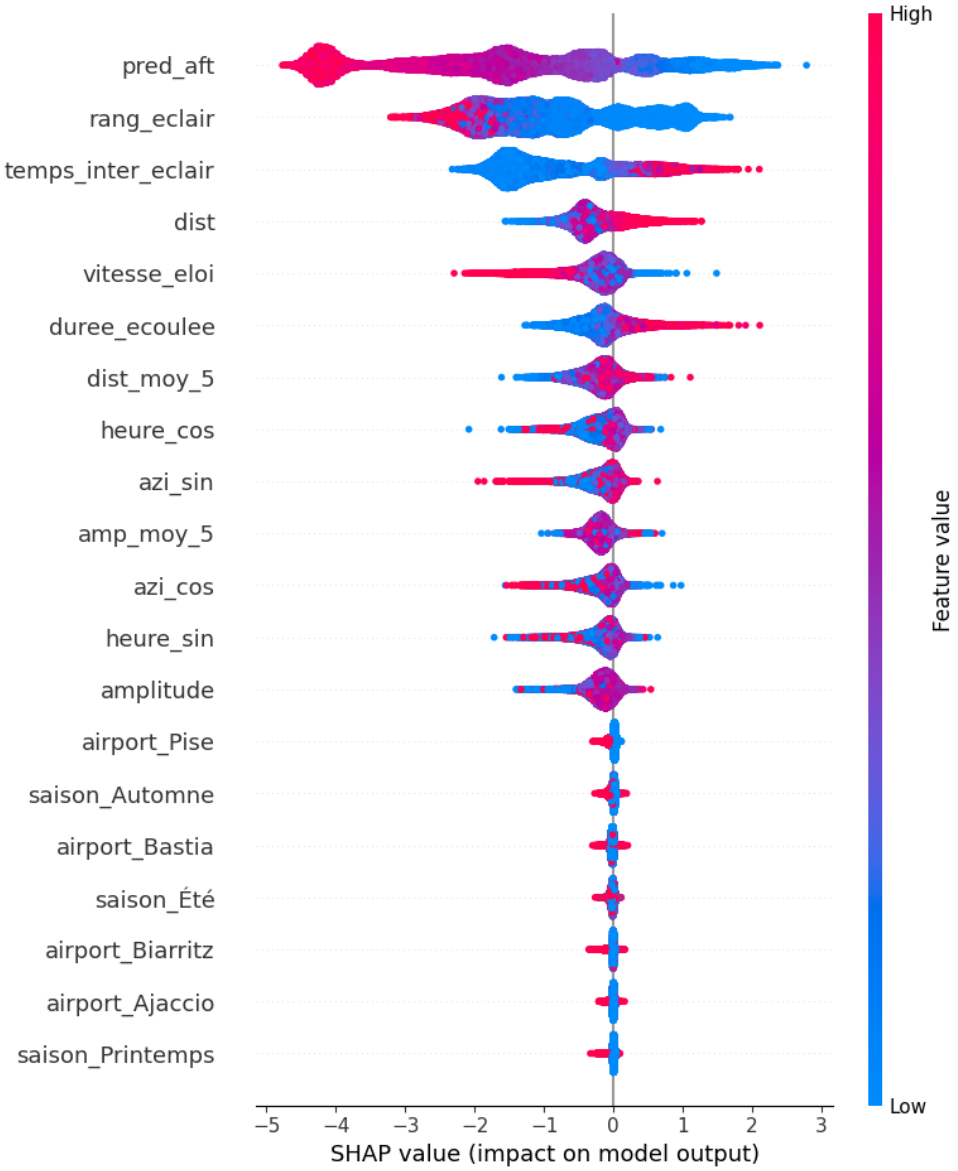

FIGURE 3 – Impact des prédicteurs

Typologie des orages autour des aéroports

4 Contexte et objectifs

La gestion opérationnelle du risque foudre constitue un enjeu majeur pour les infrastructures sensibles telles que les aéroports. Si l'anticipation de l'arrivée d'un orage est aujourd'hui relativement maîtrisée, la compréhension fine de sa dynamique reste plus complexe.

Dans ce contexte, l'objectif de cette analyse est double :

— caractériser les épisodes orageux observés autour de plusieurs aéroports européens ;
— identifier des régimes typiques d'orages à partir de leurs propriétés spatio-temporelles.

Une telle typologie permet notamment :

— d'améliorer la compréhension des mécanismes orageux locaux ;
— d'adapter les stratégies de gestion des alertes.

5 Construction d'un jeu de données au niveau des épisodes orageux

Les données initiales étant disponibles au niveau de chaque éclair, une étape d'agrégation a été réalisée afin de construire une base d'analyse au niveau des épisodes orageux.

Chaque épisode est défini comme l'ensemble des éclairs associés à une même alerte pour un aéroport donné. Cette transformation permet de passer d'une description ponctuelle du phénomène à une description globale de sa dynamique.

Après agrégation, le jeu de données contient 2627 épisodes orageux.

6 Variables descriptives des orages

Plusieurs indicateurs ont été construits afin de décrire les propriétés des épisodes :

Dynamique temporelle

— **Durée de l'orage** : différence entre le premier et le dernier éclair observé. Cet indicateur traduit la persistance du phénomène et constitue un facteur déterminant pour l'impact opérationnel.

Intensité électrique

— **Nombre total d'éclairs** : mesure globale de l'activité orageuse ;
— **Amplitude moyenne** et **amplitude maximale absolue** : indicateurs de l'énergie des décharges.

Structure spatiale

- **Distance moyenne à l'aéroport** : proximité du phénomène ;
- **Dispersion des distances** : étendue spatiale de l'orage ;
- **Dispersion angulaire** : variabilité directionnelle des éclairs.

Ces variables permettent de décrire de manière synthétique :

la sévérité, la durée et l'organisation spatiale des orages.

7 Prétraitement des données

Les variables quantitatives ont été centrées et réduites afin d'assurer leur comparabilité. Certaines variables de dispersion pouvant être manquantes pour des épisodes comportant peu d'éclairs, ces valeurs ont été imputées par zéro.

Ce prétraitement garantit la stabilité des méthodes de classification appliquées par la suite.

8 Identification des régimes orageux

Une classification non supervisée de type K**-means** a été appliquée afin de regrouper les épisodes présentant des caractéristiques similaires.

Le nombre de clusters a été fixé à $K = 3$, permettant de distinguer des profils d'orages interprétables d'un point de vue opérationnel.

La répartition des épisodes est la suivante :

Cluster	Nombre d'épisodes
1	51
2	1026
3	1550

Cette distribution met en évidence :

- l'existence d'épisodes rares mais extrêmement actifs ;
- une majorité d'orages courts et faiblement perturbateurs ;
- une proportion significative d'orages intermédiaires.

9 Interprétation des profils d'orages

Cluster 1 : Orages sévères et persistants Ces épisodes se caractérisent par :

- une durée moyenne d'environ 227 minutes ;
- une activité électrique très intense (environ 469 éclairs en moyenne) ;
- une forte dispersion spatiale.

Ils correspondent à des systèmes orageux structurés et durables, susceptibles de provoquer des perturbations majeures de l'activité aéroportuaire.

Cluster 2 : Orages modérés Ce groupe représente des épisodes de durée intermédiaire (environ 56 minutes) et d'intensité moyenne. Ces situations correspondent aux conditions orageuses les plus fréquentes et constituent un enjeu important pour l'optimisation des décisions opérationnelles.

Cluster 3 : Orages courts et localisés Ces épisodes sont caractérisés par :

- une durée moyenne très faible (environ 6 minutes) ;
- un nombre limité d'éclairs ;
- une activité électrique plus diffuse.

Ils représentent la majorité des événements observés et ont généralement un impact opérationnel limité.

10 Variabilité géographique

L'analyse de la répartition des clusters selon les aéroports met en évidence des spécificités locales.

Les aéroports situés en zone méditerranéenne présentent notamment une proportion plus élevée d'orages intenses, tandis que d'autres sites sont principalement affectés par des épisodes courts.

Ces résultats suggèrent l'influence :

- des conditions climatiques régionales ;
- de la topographie ;
- des régimes météorologiques dominants.

11 Apport de l'analyse pour la modélisation prédictive

La typologie obtenue constitue une étape essentielle pour :

- mieux comprendre les dynamiques orageuses ;
- identifier les situations à risque ;

Elle permet notamment d'envisager :

- des modèles spécifiques à chaque type d'orage ;
- des stratégies adaptatives de gestion des alertes ;
- une amélioration de la prise de décision en temps réel.

Perspectives

Les résultats obtenus dans ce travail ouvrent plusieurs perspectives particulièrement prometteuses, tant sur le plan méthodologique que sur le plan opérationnel.

12 Modélisation spatio-temporelle avancée

Les orages présentent une organisation spatiale complexe liée aux conditions atmosphériques locales. L'utilisation de modèles spatio-temporels plus sophistiqués constitue donc une piste particulièrement intéressante.

Par exemple :

— modèles de processus ponctuels spatio-temporels ;
— réseaux de neurones récurrents ou architectures de type *Transformer temporel* ;
— modèles de diffusion ou de propagation permettant de décrire la trajectoire des cellules orageuses.

Ces approches permettraient d'améliorer la compréhension de la structure interne des orages et d'anticiper plus finement leur évolution.

13 Personnalisation des modèles par aéroport

Les analyses exploratoires ont mis en évidence des spécificités locales dans la dynamique des orages. Une perspective importante consiste donc à développer :

— des modèles adaptés à chaque aéroport ;
— ou des approches hiérarchiques intégrant à la fois des effets globaux et des effets locaux.

Cette personnalisation permettrait d'améliorer significativement les performances prédictives tout en tenant compte des particularités climatiques et géographiques de chaque site.

14 Intégration de données météorologiques multi-sources

Une autre piste d'amélioration consiste à enrichir les modèles en intégrant des sources d'information complémentaires telles que :

— données radar météorologique ;
— observations satellitaires ;
— variables atmosphériques (température, humidité, pression, vent).

La fusion de ces données hétérogènes pourrait permettre de mieux caractériser l'état physique des cellules orageuses et d'améliorer la robustesse des prédictions.

15 Optimisation de la prise de décision opérationnelle

Au-delà de la prédiction elle-même, une perspective majeure réside dans la formalisation d'outils d'aide à la décision.

Il serait notamment possible de développer :

— des stratégies de décision basées sur le risque probabiliste ;
— des seuils d'alerte adaptatifs dépendant du type d'orage ;
— des tableaux de bord interactifs permettant une visualisation en temps réel de l'évolution du risque.

Ces outils pourraient contribuer à réduire les interruptions inutiles d'activité tout en maintenant un niveau de sécurité élevé.

16 Vers une modélisation prédictive globale des phénomènes convectifs

À plus long terme, les approches développées dans ce projet pourraient être étendues à d'autres phénomènes météorologiques extrêmes tels que :

— les épisodes de grêle ;
— les rafales convectives ;
— les systèmes orageux de grande échelle.

L'objectif serait de construire des systèmes intégrés capables de modéliser l'ensemble du cycle de vie des événements convectifs, depuis leur formation jusqu'à leur dissipation.

Ainsi, les travaux réalisés constituent une première étape vers le développement de solutions intelligentes et adaptatives pour la gestion des risques météorologiques dans les infrastructures critiques.

Conclusion

Ce travail avait pour objectif de proposer une approche quantitative permettant d'améliorer l'estimation de la fin des épisodes orageux à proximité des aéroports. Dans un contexte opérationnel où chaque minute d'interruption peut avoir des conséquences importantes sur la sécurité, la régularité du trafic et les coûts d'exploitation, le développement d'outils d'aide à la décision fiables constitue un enjeu majeur.

L'analyse exploratoire réalisée a permis de mieux comprendre la dynamique spatio-temporelle des orages et de mettre en évidence l'existence de profils typiques d'épisodes orageux. La construction d'une typologie des orages constitue une étape essentielle pour adapter les stratégies de gestion du risque foudre en fonction des caractéristiques locales et de l'intensité des phénomènes observés.

Sur le plan méthodologique, la mise en place d'une architecture hybride combinant une modélisation de survie de type *Accelerated Failure Time* et un algorithme d'apprentissage non linéaire de type *XGBoost* a permis de proposer une approche probabiliste innovante pour l'estimation du moment réel de dissipation des orages. Cette approche permet d'intégrer simultanément l'historique temporel de l'activité électrique, la structure spatiale des impacts de foudre ainsi que des indicateurs de sénescence du phénomène orageux.

Les résultats obtenus montrent une capacité de discrimination élevée du modèle, traduite notamment par une performance AUC de l'ordre de 0,89 et un indice de concordance satisfaisant. Ces performances confirment le potentiel d'une telle approche pour réduire les durées d'alerte excessives tout en maintenant un niveau de sécurité compatible avec les contraintes opérationnelles du secteur aérien.

Au-delà des performances prédictives, ce travail met également en évidence l'intérêt d'une approche dynamique et probabiliste de la gestion du risque météorologique. Plutôt que de reposer sur des règles fixes, l'intégration de modèles statistiques permet d'adapter en temps réel les décisions opérationnelles aux caractéristiques spécifiques de chaque épisode orageux.

Plusieurs perspectives peuvent être envisagées afin de prolonger cette étude. Il serait notamment pertinent d'intégrer des variables météorologiques supplémentaires, de développer des modèles spécifiques à chaque aéroport ou encore de mettre en place des stratégies de mise à jour en ligne permettant de réviser continuellement les probabilités de fin d'orage au fur et à mesure de l'arrivée des nouvelles observations.

Ainsi, l'approche proposée ouvre la voie à une gestion plus fine et plus efficace des alertes foudre, contribuant à la fois à la sécurisation des infrastructures sensibles et à l'optimisation de la continuité des activités aéroportuaires.